Reading from the text file

```
with open("D:/Users/USER/Documents/Build LLM from Scratch/the-
verdict.txt", "r", encoding="utf-8") as f:
    raw_text = f.read()
print("Total number of character:", len(raw_text))

# next line is the code for printing first 100 characters
print(raw_text[:99])

Total number of character: 20479
I HAD always thought Jack Gisburn rather a cheap genius--though a good fellow enough--so it was no
```

Below code splits the text on spaces

```
import re
text = "Hello, world. This is test"

#r is added to consider the \ as literal characters
# \s captures the space whether it appears
# so basically we are asking python to keep a space while splitting
the text based on spaces.

result = re.split(r'(\s)', text)
print(result)

['Hello,', ' ', 'world.', ' ', 'This', ' ', 'is', ' ', 'test']
```

So far, we have splitted the text based on space..but the text also has some special character. The code below tries to split on those special characters

```
import re
text = "Hello, world. This is test"

# [,.] matches comma and a period
# | will look for either of any characters (comma or a period)

result = re.split(r'([,.]|\s)', text)
print(result)

['Hello', ',', '', '', 'world', '.', '', 'This', ' ', 'is', ' ', 'test']
```

The above result still has whitespaces which can be removed using the following code

```
result = [item for item in result if item.strip()]
print(result)
['Hello', ',', 'world', '.', 'This', 'is', 'test']
```

We need to make the code handle different other type of punctuations like question mark, quotation marks, double dashes.

```
text = "Hello, world. Is this -- a test?"
result = re.split(r'([,.:;?_!"()\']|--|\s)', text)
result = [item.strip() for item in result if item.strip()]
print(result)
['Hello', ',', 'world', '.', 'Is', 'this', '--', 'a', 'test', '?']
```

Applying the splitting done so far to 'The Verdict' text

```
preprocessed = re.split(r'([,.:;? !"()\']|--|\s)', raw text)
    preprocessed = [item.strip() for item in preprocessed if item.strip()]
['I', 'HAD', 'always', 'thought', 'Jack', 'Gisburn', 'rather', 'a',
'cheap', 'genius', '--', 'though', 'a', 'good', 'fellow', 'enough',
'--', 'so', 'it', 'was', 'no', 'great', 'surprise', 'to', 'me', 'to',
'hear', 'that', ',', 'in', 'the', 'height', 'of', 'his', 'glory', ',',
'he', 'had', 'dropped', 'his', 'painting', ', 'married', 'a',
'rich', 'widow', ',', 'and', 'established', 'himself', 'in', 'a',
'villa', 'on', 'the', 'Riviera', '.', '(', 'Though', 'I', 'rather',
'thought', 'it', 'would', 'have', 'been', 'Rome', 'or', 'Florence',
'.', ')', '"', 'The', 'height', 'of', 'his', 'glory', '"', '--',
'that', 'was', 'what', 'the', 'women', 'called', 'it', '.', 'I,
'can', 'hear', 'Mrs', '.', 'Gideon', 'Thwing', '--', 'his', 'last',
'Chicago', 'sitter', '--', 'deploring', 'his', 'unaccountable',
'abdication', '.', '"', '0f', 'course', 'it', ""', 's', 'going', 'to',
'send', 'the', 'value', 'of', 'my', 'picture', "'", 'way', 'up', ';',
'but', 'I', 'don', ""', 't', 'think', 'of', 'that', ',', 'Mr', '.',
'Rickham', '--', 'the', 'loss', 'to', 'Arrt', 'is', 'all', 'I',
'think', 'of', '.', '"', 'The', 'word', ',', 'on', 'Mrs', '.',
'Thwing', """, 's', 'lips', ',', 'multiplied', 'its', '_, 'rs', '_,',
'as', 'though', 'they', 'were', 'reflected', 'in', 'an', 'endless',
'vista', 'of', 'mirrors', '.', 'And', 'it', 'was', 'not', 'only',
'the', 'Mrs', '.', 'Thwings', 'who', 'mourned', '.', 'Had', 'not',
'the', 'Mrs', '.', 'Thwings', 'who', 'mourned', '.', 'Had', 'not',
'the', 'Mrs', '.', 'Thwings', 'who', 'mourned', '.', 'the', 'last',
'Grafton', 'Gallery', 'show', ',', 'stopped', 'me', 'before',
'Gisburn', "'", 's', '"', 'Moon-dancers', '"', 'to', 'say', ',
'with', 'tears', 'in', 'her', 'eyes', ':', '"', 'We', 'shall', 'not',
'look', 'upon', 'its', 'like', 'again', '"', '?', 'Well', '!', '--',
'even', 'through', 'the', 'face', 'the', 'fact', 'with'.
     print(preprocessed)
   'look', 'upon', 'its', 'like', 'again', '"', '?', 'Well', '!', '--', 'even', 'through', 'the', 'prism', 'of', 'Hermia', "'", 's', 'tears', 'I', 'felt', 'able', 'to', 'face', 'the', 'fact', 'with', 'equanimity', '.', 'Poor', 'Jack', 'Gisburn', '!', 'The', 'women', 'had', 'made', 'him', '--', 'it', 'was', 'fitting', 'that', 'they', 'should', 'mourn', 'him', '.', 'Among', 'his', 'own', 'sex', 'fewer', 'regrets', 'were', 'heard', ',', 'and', 'in', 'his', 'own', 'trade', 'hardly', 'a', 'murmur', '.', 'Professional', 'jealousy', '?', 'Perhaps', '.', 'If', 'it', 'were', ',', 'the', 'honour', 'of', 'the',
```

```
'craft', 'was', 'vindicated', 'by', 'little', 'Claude', 'Nutley', ',', 'who', ',', 'in', 'all', 'good', 'faith', ',', 'brought', 'out', 'in', 'the', 'Burlington', 'a', 'very', 'handsome', '"', 'obituary', '"', 'on', 'Jack', '--', 'one', 'of', 'those', 'showy', 'articles', 'stocked', 'with', 'random', 'technicalities', 'that', 'I', 'have', 'heard', '(', 'I', 'won', "'", 't', 'say', 'by', 'whom', ')', 'compared', 'to', 'Gishurn', "'", 's', 'painting', 'dod', 'co'
  'heard', '(', 'I', 'won', "'", 't', 'say', 'by', 'whom', ')',
'compared', 'to', 'Gisburn', "'", 's', 'painting', '.', 'And', 'so',
'--', 'his', 'resolve', 'being', 'apparently', 'irrevocable', '--',
'the', 'discussion', 'gradually', 'died', 'out', ',', 'and', ',',
'as', 'Mrs', '.', 'Thwing', 'had', 'predicted', ',', 'the', 'price',
'of', '"', 'Gisburns', '"', 'went', 'up', '.', 'It', 'was', 'not',
'till', 'three', 'years', 'later', 'that', ',', 'in', 'the', 'course',
'of', 'a', 'few', 'weeks', "'", 'idling', 'on', 'the', 'Riviera', ',',
'it', 'suddenly', 'occurred', 'to', 'me', 'to', 'wonder', 'why',
'Gisburn', 'had', 'given', 'up', 'his', 'painting', '.', 'On',
'reflection', ',', 'it', 'really', 'was', 'a', 'tempting', 'problem',
'.', 'To', 'accuse', 'his', 'wife', 'would', 'have', 'been', 'too',
'easy', '--', 'his', 'fair', 'sitters', 'had', 'been', 'denied',
'the', 'solace', 'of', 'saying', 'that', 'Mrs', '.', 'Gisburn', 'had',
'.', 'To', 'accuse', 'his', 'wife', 'would', 'have', 'been', 'too',
'easy', '--', 'his', 'fair', 'sitters', 'had', 'been', 'denied',
'the', 'solace', 'of', 'saying', 'that', 'Mrs', '.', 'Gisburn', 'had',
'"', 'dragged', 'him', 'down', '.', '"', 'For', 'Mrs', '.', 'Gisburn',
'--', 'as', 'such', '--', 'had', 'not', 'existed', 'till', 'nearly',
'a', 'year', 'after', 'Jack', """, 's', 'resolve', 'had', 'been',
'taken', '.', 'It', 'might', 'be', 'that', 'he', 'had', 'married',
'her', '--', 'since', 'he', 'liked', 'his', 'ease', '--', 'because',
'he', 'didn', """, 't', 'want', 'to', 'go', 'on', 'painting', ';',
'but', 'it', 'would', 'have', 'been', 'hard', 'to', 'prove', 'that',
'he', 'had', 'given', 'up', 'his', 'painting', 'because', 'he', 'had',
'married', 'her', '.', 'Off', 'course', ',', 'if', 'she', 'had', 'not',
'dragged', 'him', 'down', ',', 'she', 'had', 'equally', ',, 'as',
'Miss', 'Croft', 'contended', ',', 'failed', 'to', '"', 'lift', 'him',
'up', '"', '--', 'she', 'had', 'not', 'led', 'him', 'back', 'to',
'the', 'easel', '.', 'To', 'put', 'the', 'brush', 'into', 'his',
'hand', 'again', '--', 'what', 'a', 'vocation', 'for', 'a', 'wife',
'!', 'But', 'Mrs', '.', 'Gisburn', 'appeared', 'to', 'have',
'disdained', 'it', '--', 'and', 'I', 'felt', 'it', 'might', 'be',
'interesting', 'to', 'find', 'out', 'why', '.', 'The', 'desultory',
'life', 'of', 'the', 'Riviera', 'lends', 'itself', 'to', 'such',
'purely', 'academic', 'speculations', ';', 'and', 'having', ',', 'on',
'my', 'way', 'to', 'Monte', 'Carlo', ',', 'caught', 'a', 'glimpse',
'of', 'Jack', "'", 's', 'balustraded', 'terraces', 'between', 'the',
'pines', ',', 'I', 'had', 'myself', 'borne', 'thither', 'the', 'next',
'day', '.', 'I', 'had', 'myself', 'borne', 'thither', 'the', 'next',
'day', '.', 'I', 'had', 'myself', 'borne', 'thither', 'the', 'next',
'weeks', ',', 'I', 'claimed', 'it', 'frequently', '.', 'It', 'was',
'not', 'that', 'my', 'hostess', 'was', '"', 'interesting', '"', ':',
'on', 'that', 'point', 'I', ''could', 'have', 'diven', 'Miss', 'Cr
       'not', 'that', 'my', 'hostess', 'was', '"', 'interesting', '"', ':',
'on', 'that', 'point', 'I', 'could', 'have', 'given', 'Miss', 'Croft',
'the', 'fullest', 'reassurance', '.', 'It', 'was', 'just', 'because',
'she', 'was', '_', 'not', '_', 'interesting', '--', 'if', 'I', 'may',
```

```
'be', 'pardoned', 'the', 'bull', '--', 'that', 'I', 'found', 'her', 'so', '.', 'For', 'Jack', ',', 'all', 'his', 'life', ',', 'had', 'been', 'surrounded', 'by', 'interesting', 'women', ':', 'they', 'had', 'fostered', 'his', 'art', ',', 'it', 'had', 'been', 'reared', 'in', 'the', 'hot-house', 'of', 'their', 'adulation', '.', 'And', 'it', 'was', 'therefore', 'instructive', 'to', 'note', 'what', 'effect', 'the', '"', 'deadening', 'atmosphere', 'of', 'mediocrity', '"', 'I', 'dunte', 'Miss', 'Croft', ')', 'was', 'having', 'on'
'it', 'was', 'therefore', 'instructive', 'to', 'note', 'what',
'effect', 'the', '"', 'deadening', 'atmosphere', 'of', 'mediocrity',
'"', '(', 'I', 'quote', 'Miss', 'Croft', ')', 'was', 'having', 'on',
'him', '.', 'I', 'have', 'mentioned', 'that', 'Mrs', '.', 'Gisburn',
'was', 'rich', ';', 'and', 'it', 'was', 'immediately', 'perceptible',
'that', 'her', 'husband', 'was', 'extracting', 'from', 'this',
'circumstance', 'a', 'delicate', 'but', 'substantial', 'satisfaction',
'.', 'It', 'is', ', 'as', 'a', 'rule', ', 'the', people', 'who',
'scorn', 'money', 'who', 'get', 'most', 'out', 'of', 'it', ';', 'and',
'Jack', ""', 's', 'elegant', 'disdain', 'of', 'his', 'wife', ""', 's',
'big', 'balance', 'enabled', 'him', ',', 'with', 'an', 'appearance',
'of', 'perfect', 'good-breeding', ', 'to', 'transmute', 'it',
'into', 'objects', 'of', 'art', 'and', 'luxury', '.', 'To', 'the',
'latter', ',', 'I, 'must', 'add', ', 'he', 'remained',
'relatively', 'indifferent', ';', 'but', 'he', 'was', 'buying',
'Renaissance', 'bronzes', 'and', 'eighteenth-century', 'pictures',
'with', 'a', 'discrimination', 'that', 'bespoke', 'the', 'amplest',
'resources', ',' "', 'Money', ""', 's', 'only', 'excuse', 'is',
'to', 'put', 'beauty', 'into', 'circulation', ',', "', 'was', 'one',
'of', 'the', 'axioms', 'he', 'laid', 'down', 'across', 'the',
'Sevres', 'and', 'silver', 'of', 'an', 'exquisitely', 'appointed',
'Luncheon-table', ',', 'when', ',', 'orm', 'Monte', 'Cay', ','
'and', 'again', 'run', 'over', 'from', 'Monte', 'Cay', ','
'and', 'Mrs', '.', 'Gisburn', ',', 'beaming', 'on', 'him', ','
'added', 'for', 'my', 'enlightenment', ':', '"', 'Jack', 'is', 'so',
'morbidly', 'sensitive', 'to', 'every', 'form', 'of', 'beauty', ','
'"', 'Poor', 'Jack', '!', 'It', 'had', 'always', 'been', 'his',
'"', 'Poor', 'Jack', '!', 'It', 'had', 'always', 'been', 'his',
's', 'the', 'fact', 'should', 'be', 'set', 'down', 'in',
'extenuation', '.', 'What', 'struck', 'me', 'now', 'was', 'that', ',
'for', 'the', 'first', 'time', ',', 'he', 'resented', 'the', 'tone',
'
       'for', 'the', 'first', 'time', ',', 'he', 'resented', 'the', 'tone', '.', 'I', 'had', 'seen', 'him', ',', 'so', 'often', ',', 'basking', 'under', 'similar', 'tributes', '--', 'was', 'it', 'the', 'conjugal', 'note', 'that', 'robbed', 'them', 'of', 'their', 'savour', '?', 'No', '--', 'for', ',', 'oddly', 'enough', ',', 'it', 'became', 'apparent', 'that', 'he', 'was', 'fond', 'of', 'Mrs', '.', 'Gisburn', '--', 'fond', 'enough', 'not', 'to', 'see', 'her', 'absurdity', '.', 'It', 'was', 'his', 'own', 'absurdity', 'he', 'seemed', 'to', 'he'
       'was', 'his', 'own', 'absurdity', 'he', 'seemed', 'to', 'be', 'wincing', 'under', '--', 'his', 'own', 'attitude', 'as', 'an', 'object', 'for', 'garlands', 'and', 'incense', '.', '"', 'My', 'dear', ',', 'since', 'I', "'", 've', 'chucked', 'painting', 'people', 'don', "'", 't', 'say', 'that', 'stuff', 'about', 'me', '--', 'they', 'say', 'it', 'about', 'Victor', 'Grindle', ',', '"', 'was', 'his', 'only', 'protest', ',', 'as', 'he', 'rose', 'from', 'the', 'table', 'and',
```

```
'strolled', 'out', 'onto', 'the', 'sunlit', 'terrace', '.', 'I', 'glanced', 'after', 'him', ',', 'struck', 'by', 'his', 'last', 'word', '.', 'Victor', 'Grindle', 'was', ',', 'in', 'fact', ',', 'becoming', 'the', 'man', 'of', 'the', 'moment', '--', 'as', 'Jack', 'himself', ',', 'one', 'might', 'put', 'it', ',', 'had', 'been', 'the', 'man', 'of', 'the', 'hour', '.', 'The', 'younger', 'artist', 'was', 'said', 'to', 'have', 'formed', 'himself', 'at', 'my', 'friend', "'", 's', 'feet', ',', 'and', 'I', 'wondered', 'if', 'a', 'tinge', 'of', 'jealousy', 'underlay', 'the', 'latter', "'", 's', 'mysterious', 'abdication', '.', 'But', 'no', '--', 'for', 'it', 'was', 'not', 'till', 'after', 'that', 'event', 'that', 'the', '_, 'rose', 'Dubarry', '_, 'drawing-rooms', 'had', 'begun', 'to', 'display', 'their', '"', 'Grindles', '.', '"', 'I', 'turned', 'to', 'Mrs', '.', 'Gisburn', ',', 'who', 'had', 'lingered', 'to', 'give', 'a', 'lump', 'of', 'sugar', 'to', 'her', 'spaniel', 'in', 'the', 'dining-room', '.', '"', 'Why', '_, 'has', '_, 'he', 'chucked', 'painting', '?', '"', 'I', 'asked', 'abruptly', '.', 'She', 'raised', 'her', 'eyebrows', 'with', 'a', 'hint', 'of', 'good-humoured', 'surprise', '.', '"', 'Oh', ', 'he', 'doesn', ""', 't', 'and', 'I', 'want', 'him', 'to', 'enjoy', 'himself', ',', '"', 'she', 'said', 'quite', 'simply', '.', 'I', 'looked', 'about', 'the', 'spacious', 'white-panelled', 'room', ',', 'with', 'its', '_, 'famille-verte', '_, 'vases', 'repeating', 'the', 'tones', 'of', 'the', 'pale', 'damask', 'curtains', ',', 'and', 'its', 'eighteenth-century', 'pastels', 'in', 'delicate', 'faded', 'frames', '.', '"', 'Has', 'he', 'chucked', 'his', 'pictures', 'too', '?'. 'I'. 'haven', ""'". 't'. 'seen'. 'a'. 'single'. 'one'. 'in'.
    'its', 'eignteenth-century', 'pastels', 'in', 'delicate', 'faded', 'frames', '.', '"', 'Has', 'he', 'chucked', 'his', 'pictures', 'too', '?', 'I', 'haven', "'", 't', 'seen', 'a', 'single', 'one', 'in', 'the', 'house', '.', '"', 'A', 'slight', 'shade', 'of', 'constraint', 'crossed', 'Mrs', '.', 'Gisburn', "'", 's', 'open', 'countenance', '.', 'It', "It', "'", 's', 'his', 'ridiculous', 'modesty', ',', 'you', 'know', '.', 'He', 'says', 'they', "'", 're', 'not', 'fit', 'to', 'have', 'about', ';', 'he', "'", 's', 'sent', 'them', 'all', 'away', 'except', 'one', '--', 'my', 'portrait', '--', 'and', 'that', 'I', 'have', 'to', 'keen', 'unstairs', '-', 'm', 'ridiculous'
     'except', 'one', '--', 'my', 'portrait', '--', 'and', 'that', 'I',
'have', 'to', 'keep', 'upstairs', '.', '"', 'His', 'ridiculous',
'modesty', '--', 'Jack', "'", 's', 'modesty', 'about', 'his',
'pictures', '?', 'My', 'curiosity', 'was', 'growing', 'like', 'the',
'bean-stalk', '.', 'I', 'said', 'persuasively', 'to', 'my', 'hostess',
':', '"', 'I', 'must', 'really', 'see', 'your', 'portrait', ',',
'you', 'know', '.', '"', 'She', 'glanced', 'out', 'almost',
'timorously', 'at', 'the', 'terrace', 'where', 'her', 'husband', ',',
'lounging', 'in', 'a', 'hooded', 'chair', ', 'had', 'lit', 'a'
    'timorously', 'at', 'the', 'terrace', 'where', 'her', 'husband', ',', 'lounging', 'in', 'a', 'hooded', 'chair', ',', 'had', 'lit', 'a', 'cigar', 'and', 'drawn', 'the', 'Russian', 'deerhound', "'", 's', 'head', 'between', 'his', 'knees', '.', '"', 'Well', ',', 'come', 'while', 'he', "'", 's', 'not', 'looking', ',', '"', 'she', 'said', ',', 'with', 'a', 'laugh', 'that', 'tried', 'to', 'hide', 'her', 'nervousness', ';', 'and', 'I', 'followed', 'her', 'between', 'the', 'marble', 'Emperors', 'of', 'the', 'hall', ',', 'and', 'up', 'the', 'wide', 'stairs', 'with', 'terra-cotta', 'nymphs', 'poised', 'among', 'flowers', 'at', 'each', 'landing', '.', 'In', 'the', 'dimmest',
```

```
'corner', 'of', 'her', 'boudoir', ',', 'amid', 'a', 'profusion', 'of', 'delicate', 'and', 'distinguished', 'objects', ',', 'hung', 'one', 'of', 'the', 'familiar', 'oval', 'canvases', ', 'in', 'the', 'inevitable', 'garlanded', 'frame', '. 'The', 'mere', 'outline', 'of', 'the', 'frame', 'called', 'up', 'all', 'Gisburn', "'', 's', 'past', '!', 'Mrs', ', 'Gisburn', 'drew', 'back', 'the', 'window-curtains', ', 'moved', 'aside', 'a', ', 'jardiniere', ', 'full', 'of', 'pink', 'azaleas', ',', 'pushed', 'an', 'arm-chair', 'away', ', 'and', 'said', ':', '"', 'If', 'you', 'stand', 'here', 'you', 'can', 'just', 'manage', 'to', 'see', 'it', '.', 'I', 'had', 'it', 'over', 'the', 'manage', 'to', 'see', 'it', '-', 'the', 'wouldn', "", 't, 'let', 'it', 'stay', '.', ''Yes', '--', 'I', 'could', 'just', 'manage', 'to', 'see', 'it', '--', 'the', 'first', 'portrait', 'of', 'Jack', "", 's', 'I', 'had', 'ever', 'had', 'the', 'place', 'of', 'honour', '--', 'say', 'the', 'central', 'panel', 'in', 'a', 'pale', 'yellow', 'or', '_, 'rose', 'Dubarry', '_, 'drawing-room', ', 'or', 'a', 'monumental', 'easel', 'placed', 'so', 'that', 'it', 'took', 'the', 'light', 'through', 'curtains', 'of', 'old'
'Venetian', 'point', '.', 'The', 'more', 'modest', 'place', 'became', 'the', 'picture', 'better', ';', 'yet', ', 'as', 'my', 'eyes', 'grew', 'accustomed', 'to', 'the', 'malf-light', ', 'all', 'the', 'characteristic', 'qualities', 'came', 'out', '--', 'all', 'the', 'characteristic', 'qualities', 'came', 'out', '--', 'all', 'the', 'consummate', 'skill', ',', 'he', 'managed', 'to', 'divert', 'attention', 'from', 'the', 'real', 'business', 'of', 'detail', ',', 'Mrs', '.' Gisburn', ',', 'presenting', 'a', 'neutral', 'surface', 'to', 'work', 'on', '--', 'forming', ',', 's', 'wore', ',', 's', '"', 'so', 'inevitably', 'the', 'background', 'of', 'her', 'own', 'picture', 'was', 'one', 'of', 'laet', 'own', 's', '"', 's', 'swelling', 'of', 'muscles', ',', 'a', 'congesting', 'of', 'veins', ',', 'a', 'balacning', ',', 'straddling', 'and', 'straning', 'of', 'the', 
             ',', 'that', 'reminded', 'one', 'of', 'the', 'circus-clown', "'", 's', 'ironic', 'efforts', 'to', 'lift', 'a', 'feather', '.', 'It', 'met', ',', 'in', 'short', ',', 'at', 'every', 'point', 'the', 'demand', 'of', 'lovely', 'woman', 'to', 'be', 'painted', '"', 'because', 'she', 'was', 'tired', 'of', 'being', 'painted', '"', 'sweetly', '"', '--', 'and', 'yet', 'not', 'to', 'lose', 'an', 'atom', 'of', 'the', 'sweetness', '.', '"', 'It', "'", 's', 'the', 'last', 'he', 'painted', ',', 'you', 'know', ',', '"', 'Mrs', '.', 'Gisburn', 'said', 'with', 'pardonable', 'pride', '.', '"', 'The', 'last', 'but', 'one', ',', '"', 'she', 'corrected', 'herself', '--', '"', 'but', 'the', 'other', 'doesn', "'", 't', 'count', ',', 'because', 'he',
```

```
'destroyed', 'it', '.', '"', '"', 'Destroyed', 'it', '?', '"', 'I', 'was', 'about', 'to', 'follow', 'up', 'this', 'clue', 'when', 'I', 'heard', 'a', 'footstep', 'and', 'saw', 'Jack', 'himself', 'on', 'the', 'threshold', '.', 'As', 'he', 'stood', 'there', ',', 'his', 'hands', 'in', 'the', 'pockets', 'of', 'his', 'velveteen', 'coat', ',', 'the', 'thin', 'brown', 'waves', 'of', 'hair', 'pushed', 'back', 'from', 'his', 'white', 'forehead', ',', 'his', 'lean', 'sunburnt', 'cheeks' 'furrowed' 'by' 'a' 'smile' 'that' 'lifted' 'the'
'hands', 'in', 'the', 'pockets', 'of', 'his', 'velveteen', 'coat',
', 'the', 'thin', 'brown', 'waves' 'of', 'hair', 'pushed', 'back',
'from', 'his', 'white', 'forehead', ', 'his', 'lean', 'sunburnt',
'cheeks', 'furrowed', 'by', 'a', 'smile', 'that', 'lifted', 'the',
'tips', 'of', 'a', 'self-confident', 'moustache', ', 'I', 'felt',
'to', 'what', 'a', 'self-confident', 'moustache', ', 'I', 'felt',
'to', 'what', 'a', 'self-confident', 'moustache', ', 'I', 'felt',
'to', 'what', 'a', 'self-confident', 'moustache', ', 'I', 'felt',
'as', 'his', 'pictures', '--', 'the', 'quality', 'of', 'looking',
'cleverer', 'than', 'he', 'was', '.' 'His', 'wife', 'glanced', 'at',
'him', 'deprecatingly', ', 'but', 'his', 'eyes', 'travelled',
'past', 'her', 'to', 'the', 'portrait', ', '", 'Mr', ',
'Rickham', 'wanted', 'to', 'see', 'it', ', 'shrugged', 'his',
'shoulders', ', 'still', 'smiling', ', '"', 'he', 'said',
'lightly', 'g', 'then', 'g', passing', 'his', 'arm', 'through',
'mine', ':', "'', 'He', 'showed', 'it', 'to', 'me', 'with', 'a',
'kind', 'of', 'naive', 'suburban', 'pride', ';', 'the', 'bath-rooms',
', 'the', 'speaking-tubes', ', 'the', 'dress-closets', ', 'the',
'trouser-presses', '--, 'all', 'the', 'complex', 'simplifications',
'of', 'the', 'millionaire', "", 's', 'domestic', 'economy', ',
'And', 'whenever', 'my', 'wonder', 'paid', 'the', 'expected',
'tribute', 'he', 'said', ', 'throwing', 'out', 'his', 'chest', 'a',
'little', ':', ''', 'Yes', 'I', 'really', 'don', '"", 't', 'see',
'how', 'people', 'manage', 'to', 'live', 'without', 'that', 'one', 'have', 'foreseen', 'for', 'him', ', 'only', 'he', 'was', ','
'through', 'it', 'all', 'and', 'in', 'spite', 'of', 'it', 'all', '--,
'as', 'he', 'had', 'been', 'throwing', ', 'so', 'charming',
', 'so', 'disarming', ', 'that', 'one', 'longed', 'to', 'rey,
'out', '!', 'Be', 'dissatisfied', with', 'your', 'leading', 'me', 'into',
'a', 'a', 'his', 'pictures', '--', 'so', 'handsome', ', 'so', 'charming',
'a', 'she', 'had', 'in', 'spite', 'of', 'the', 'buo',
'a', 'dark', plain', 'rom',
```

```
"with', 'his', 'old', 'life', '.', '"', 'Don', """, 't', 'you',
'ever', 'dabble', 'with', 'paint', 'any', 'more', ?', '"', 'I',
'asked', ', 'still', 'looking', 'about', 'for', 'a', 'trace', 'of',
'such', 'activity', '", 'Never', ', '"', 'he', 'said',
briefly', ', '", 'Or', 'water-colour', '--', 'or', 'etching', ?',
'"', 'His', 'confident', 'eyes', 'grew', 'dim', ', 'and', 'his',
'cheeks', 'paled', 'a', 'little', 'under', 'their', 'handsome',
'sunburn', ', '", 'Never', 'think', 'of', 'it', ', 'my', 'dear',
'fellow', '--', 'any', 'more', 'than', 'if', 'I', "", 'd', 'never',
'touched', 'a', 'brush', ', '"', 'And', 'his', 'tone', 'told', 'me',
'in', 'a', 'flash', 'that', 'he', 'never', 'thought', 'of',
'anything', 'else', ', 'I', 'moved', 'away', ', 'instinctively,
'embarrassed', 'by', 'my', 'unexpected', 'discovery', ', 'and',
'as', 'I', 'turned', ', 'my', 'eye', 'fell', 'on', 'a', 'small',
'picture', 'above', 'the', 'mantel-piece', '--', 'the', 'only,'
'object', 'breaking', 'the', 'plain', 'oak', 'panelling', 'of', 'the',
'room', ', '", 'Oh', ', 'by', 'Jove', '!', '"', 'I', 'said', ',
'It', 'was', 'a', 'sketch', 'of', 'a', 'donkey', '--', 'an', 'old',
'tired', 'donkey', ', 'standing', 'in', 'the', 'rain', 'under', 'a',
'wall', ', '", 'By', 'Jove', '--', 'a', 'Stroud', '!', '"', 'I',
'cried', 'dhe', 'was', 'silent', ', 'but', 'I', 'felt', 'him',
'close', 'behind', 'me', ', 'breathing', 'a', 'little', 'quickly',
', '", 'What', 'a', 'wonder', '!', 'Made', 'with', 'a', 'dozen',
'lines', '--', 'but', 'on', 'everlasting', 'foundations', '.', 'You',
'lucky', 'chap', ',', 'where', 'did', 'you', 'get', 'it', '?', '"',
'He', 'answered', 'slowly', ', '", 'Mrs', ', 'Stroud', 'gave',
'it', 'to', 'me', 'shew', 'the', 'Strouds', ', 'He', 'was',
'such', 'an', 'inflexible', 'hermit', ', ', ', 'She', 'sent', 'for',
'me', 'to', 'paint', 'him', 'when', 'he', 'sarswered', 'with',
'a', 'deprecating', 'lagh', '', 'you', 'know', ', 'Mrs', '.'
'"', 'When', 'he', 'dashionable', 'painter', '-, 'n', 'h',
'a', 'purblind', 'public', '.' 
        'proclaiming', 'his', 'greatness', '--', 'of', 'forcing', 'it', 'on', 'a', 'purblind', 'public', '.', 'And', 'at', 'the', 'moment', 'I', 'was', '_', 'the', '_', 'fashionable', 'painter', '.', 'Was', '_', 'history', '--', 'as', 'you', 'say', '.', 'Was', '_', 'that', '_', 'history', '?', '"', '"', 'That', 'was', 'his', 'history', '.', 'She', 'believed', 'in', 'him', ',', 'gloried', 'in', 'him', '--', 'or', 'thought', 'she', 'did', '.', 'But', 'she', 'couldn', "'", 't', 'bear', 'not', 'to', 'have', 'all', 'the', 'drawing-rooms', 'with', 'her', '.', 'She', 'couldn', "'", 't', 'bear', 'the', 'fact', 'that', ',', 'on', 'varnishing', 'days', ',',
```

```
'the', 'stream',',' 'echoed', 'the', 'usual', 'platitudes', 'about', 'him', ', 'till, 'I', 'half', 'got', 'to', 'think', 'he', 'was', 'a', 'failure', ', 'one', 'of', 'the', 'kind', 'that', 'are', 'left', 'behind', '. 'By', 'Jove', ', 'and', 'to', 'let', 'was', '_', 'left', 'behind', '--', 'because', 'he', 'had', 'come', 'to', 'stay', '!', 'The', 'rest', 'of', 'us', 'had', 'to', 'let', 'ourselves', 'be', 'swept', 'along', 'or', 'go', 'under', ', 'but', 'he', 'was', 'high', 'above', 'the', 'current', '--', 'on', 'everlasting', 'foundations', ', 'as', 'you', 'say', ', ''', 'well', ', 'I', 'went', 'off', 'to', 'the', house', 'in', 'my', 'most', 'egregious', 'mood', '--', 'rather', 'moved', ', 'Lord', 'forgive', 'me', ', 'at', 'the', 'pathos', 'of', 'poor', 'Stroud', '"'', 's', 'career', 'of', 'failure', 'being', 'crowned', 'by', 'the', 'glory', 'of', 'my', 'painting', 'him', '!', 'fo', 'course', 'I', 'meant', 'to', 'do', 'the', 'picture', 'for', 'nothing', '--', 'I', 'told', 'Mrs', 'Stroud', 'so', 'when', 'she', 'began', 'to', 'stammer', 'something', 'about', 'her', 'poverty', 'I', 'remember', 'getting', 'off', 'a', 'prodigious', 'phrase', 'about', 'the', 'honour', 'being', 'mine', '--', 'oh', 'I', 'was', 'princely', ', 'my', 'dear', 'Rickham', '!', 'I', 'was', 'posing', 'to', 'myself', 'lake', 'one', 'of', 'my', 'own', 'Sitters', ', '"'' Then', 'I', 'was', 'taken', 'up', 'and', 'letf', 'alone', 'with', 'him', 'I', 'had', 'sent', 'all', 'my', 'traps', 'in', advance', ', 'and', 'I', 'was', 'superb', ', 'I', 'was', 'glad', 'at', 'here', 'had', 'been', 'do', 'heart', 'disease', ', 'so', 'that', 'there', 'had', 'been', 'do', 'heart', 'disease', ', 'so', 'that', 'there', 'had', 'been', 'do', 'was', 'superb', ', 'I', 'was', 'glad', 'at', 'first', 'was', 'superb', ', 'I', 'was', 'glad', 'at', 'first', 'he', 'was', 'yy, 'strokes', 'began', 'to', 'my', 'and', 'uncertain', 'mo', 'was', 'bo', 'my', 'strokes', 'began', 'to', 'my', 'and', 'were', 'watching', 'me', 'what', 'would', 'he', 'say, 'to', 'my', 'serned', 'be', 'had', 
                'back', 'from', 'me', '.', 'That', 'exasperated', 'me', 'still', 'more', '.', 'The', 'secret', '?', 'Why', ',', 'I', 'had', 'a', 'secret', 'worth', 'twenty', 'of', 'his', '!', 'I', 'dashed', 'at',
```

```
'the', 'canvas', 'furiously', ',', 'and', 'tried', 'some', 'of', 'my', 'bravura', 'tricks', '.', 'But', 'they', 'failed', 'me', ',', 'they', 'crumbled', '.', 'I', 'saw', 'that', 'he', 'wasn', "'", 't', 'watching', 'the', 'showy', 'bits', '--', 'I', 'couldn', "'", 't', 'distract', 'his', 'attention', ';', 'he', 'just', 'kept', 'his', 'eyes', 'on', 'the', 'hard', 'passages', 'between', '.', 'Those', 'were', 'the', 'ones', 'I', 'had', 'always', 'shirked', ',', 'or', 'covered', 'up', 'with', 'some', 'lying', 'paint', '.', 'And', 'how', 'he', 'saw', 'through', 'my', 'lies', '!', '"', 'I', 'looked', 'up', 'again', ',', 'and', 'caught', 'sight', 'of', 'that', 'sketch', 'of', 'the', 'donkey', 'hanging', 'on', 'the', 'wall', 'near', 'his', 'bed', '.', 'His', 'wife', 'told', 'me', 'afterward', 'it', 'was', 'the', 'last', 'thing', 'he', 'had', 'done', '--', 'just', 'a', 'note',
        'last', 'thing', 'he', 'had', 'done', '--', 'just', 'a', 'note', 'taken', 'with', 'a', 'shaking', 'hand', ',', 'when', 'he', 'was', 'down', 'in', 'Devonshire', 'recovering', 'from', 'a', 'previous',
'taken', 'with', 'a', 'shaking', 'hand', ',', 'wnen', 'ne', 'was', 'down', 'in', 'Devonshire', 'recovering', 'from', 'a', 'previous', 'heart', 'attack', '.', 'Just', 'a', 'note', '!', 'But', 'it', 'tells', 'his', 'whole', 'history', '.', 'There', 'are', 'years', 'of', 'patient', 'scornful', 'persistence', 'in', 'every', 'line', '.', 'A', 'man', 'who', 'had', 'swum', 'with', 'the', 'current', 'could', 'never', 'have', 'learned', 'that', 'mighty', 'up-stream', 'stroke', '.', '.', '.', '.', '"', 'I', 'turned', 'back', 'to', 'my', 'work', ',', 'and', 'went', 'on', 'groping', 'and', 'muddling', ';', 'then', 'I', 'looked', 'at', 'the', 'donkey', 'again', '.', 'I', 'saw', 'that', ',', 'when', 'Stroud', 'laid', 'in', 'the', 'first', 'stroke', ',', 'he', 'knew', 'just', 'what', 'the', 'end', 'would', 'be', '.', 'He', 'had', 'possessed', 'his', 'subject', ',', 'absorbed', 'it', ',', 'recreated', 'it', '.', 'When', 'had', 'I', 'done', 'that', 'with', 'any', 'of', 'my', 'things', '?', 'They', 'hadn', "'", 't', 'been', 'born', 'of', 'me', '--, 'I', 'had', 'just', 'adopted', 'them', '.', '.', '.', '"', 'Hang', 'it', ',', 'Rickham', ',', 'with', 'that', 'face', 'watching', 'me', 'I', 'couldn', """, 't', 'do', 'another', 'stroke', '.', 'The', 'plain', 'truth', 'was', ',', 'I', 'didn', """, 't', 'known', 'where', 'to', 'put', 'it', '--, '_', 'I', 'lad', 'never', 'known', '_', ',', 'a', 'showy', 'splash', 'of', 'colour', 'covered', 'up', 'the', 'faces', 't', 'The', 'faces'
 'Only', ',', 'with', 'my', 'sitters', 'and', 'my', 'public', ',', 'a', 'showy', 'splash', 'of', 'colour', 'covered', 'up', 'the', 'fact', '--', 'I', 'just', 'threw', 'paint', 'into', 'their', 'faces', '.', '.', '.', '.', 'Well', ',', 'paint', 'was', 'the', 'one', 'medium', 'those', 'dead', 'eyes', 'could', 'see', 'through', '--', 'see', 'straight', 'to', 'the', 'tottering', 'foundations', 'underneath', '.', 'Don', "'", 't', 'you', 'know', 'how', ',', 'in', 'talking', 'a', 'foreign', 'language', ',', 'even', 'fluently', ',', 'one', 'says', 'half', 'the', 'time', 'not', 'what', 'one', 'wants', 'to', 'but', 'what', 'one', 'can', '?', 'Well', '--', 'that', 'was', 'the', 'way', 'I', 'painted', ';', 'and', 'as', 'he', 'lay', 'there', 'and', 'watched', 'me', ',', 'the', 'thing', 'they', 'called', 'my', "'", 'technique', "'", 'collapsed', 'like', 'a', 'house', 'of', 'cards', '.', 'He', 'didn', "'", 't', 'sneer', ',', 'you', 'understand', ',', 'poor', 'Stroud', '--', 'he', 'just', 'lay', 'there', 'quietly',
```

```
"watching', ', 'and', 'on', 'his', 'lips', ', 'through', 'the',
'gray', 'beard', ',' 'I', 'seemed', 'to', 'hear', 'the', 'question',
':' "'", 'Are', 'you', 'sure', 'you', 'know', 'where', 'you', '"",
're', 'coming', 'out', '?', """, 'If', 'I', 'could', 'have',
'painted', 'that', 'face', ', 'with', 'that', 'question', 'on',
'it', ', 'I', 'should', 'have', 'done', 'a', 'great', 'thing',
'The', 'next', 'greatest', 'thing', 'was', 'to', 'see', 'that', 'I',
'couldn', "'", 't', '--', 'and', 'that', 'grace', 'was', 'given',
'me', '. 'But', 'oh', 'a', 'that', 'minute', 'Rickham', ', 'was', 'there', 'anything', 'on', 'earth', 'I',
'wouldn', "'", 't', 'have', 'given', 'to', 'have', 'Stroud', 'alive',
'before', 'me', ', 'and', 'to', 'hear', 'him', 'say', ', "",
'It', "'", 's', 'not', 'too', 'late', '--', 'I', 'would', 'have', 'been', 'even', 'if', 'he', "",
'd', 'been', 'alive', 'I', 'packed', 'up', 'my', 'traps', ',
'and', 'went', 'down', 'and', 'told', 'Mrs', '.', 'Stroud', '.', 'of',
'course', 'I', 'didn', "'", 't', 'tell', 'her', '', 'that', '',
'and', 'was', 'too', 'moved', '.', 'She', 'rather', 'liked',
'the', 'idea', ---, 'she', "'", 's', 'so', 'romantic', '!', 'It',
'was', 'that', that', 'made', 'her', 'give', 'me', 'the', 'donkey',
'', 'But', 'she', 'was', 'terribly', 'upset', 'at', 'not', 'getting',
'the', 'portrait', '--', 'she', 'did', 'so', 'want', 'him', "'',
'done', ""', 'by', 'some', 'one', 'showy', '!', 'At', 'first', 'I',
'was', 'afraid', 'she', 'wouldn', ""', 't', 'tet', 'me', 'off', '--',
'and', 'at', 'my', 'wits', ""', 'end', 'I', 'suggested', 'Grindle', '.', ''', ''', ''', ''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''', '''',
           'he', "'", 'd', 'been', 'able', 'to', 'say', 'what', 'he', 'thought', 'that', 'day', '.', '"', 'And', ',', 'in', 'answer', 'to', 'a', 'question', 'I', 'put', 'half-mechanically', '--', '"', 'Begin', 'again', '?', '"', 'he', 'flashed', 'out', '.', '"', 'When', 'the', 'one', 'thing', 'that', 'brings', 'me', 'anywhere', 'near', 'him',
           'is', 'that', 'I', 'knew', 'enough', 'to', 'leave', 'off', '?', '"', 'He', 'stood', 'up', 'and', 'laid', 'his', 'hand', 'on', 'my', 'shoulder', 'with', 'a', 'laugh', '.', '"', 'Only', 'the', 'irony', 'of', 'it', 'is', 'that', 'I', '_', 'am', '__', 'still', 'painting', '--', 'since', 'Grindle', "'", 's', 'doing', 'it', 'for', 'me', '!',
```

```
'The', 'Strouds', 'stand', 'alone', ',', 'and', 'happen', 'once', '--', 'but', 'there', "'", 's', 'no', 'exterminating', 'our', 'kind', 'of', 'art', '.', '"']
```

Fetching first 30 words

```
print(preprocessed[:30])

['I', 'HAD', 'always', 'thought', 'Jack', 'Gisburn', 'rather', 'a',
'cheap', 'genius', '--', 'though', 'a', 'good', 'fellow', 'enough',
'--', 'so', 'it', 'was', 'no', 'great', 'surprise', 'to', 'me', 'to',
'hear', 'that', ',', 'in']
```

Counting the number of words

```
all_words = sorted(set(preprocessed))
vocab_size = len(all_words)
print(vocab_size)

1130
```

Creating a dictionary with tokens (words) and their corresponding token ids

```
vocab = {token:integer for integer,token in enumerate(all words)}
for i, item in enumerate(vocab.items()):
    print(item)
    if i >= 50:
         break
('!', 0)
('"', 1)
("'", 2)
('(', 3)
(')', 4)
(',', 5)
('--', 6)
('.', 7)
(':', 8)
(';', 9)
('?', 10)
('A', 11)
('Ah', 12)
('Among', 13)
('And', 14)
('Are', 15)
('Arrt', 16)
('As', 17)
('At', 18)
('Be', 19)
('Begin', 20)
('Burlington', 21)
```

```
('But', 22)
('By', 23)
('Carlo', 24)
('Chicago', 25)
('Claude', 26)
('Come', 27)
('Croft', 28)
('Destroyed', 29)
('Devonshire', 30)
('Don', 31)
('Dubarry', 32)
('Emperors', 33)
('Florence', 34)
('For', 35)
('Gallery', 36)
('Gideon', 37)
('Gisburn', 38)
('Gisburns', 39)
('Grafton', 40)
('Greek', 41)
('Grindle', 42)
('Grindles', 43)
('HAD', 44)
('Had', 45)
('Hang', 46)
('Has', 47)
('He', 48)
('Her', 49)
('Hermia', 50)
```

Below are the functions to encode into tokens and token ids then decode back to normal text

```
class SimpleTokenizerV1:
    def __init__(self, vocab):
        self.str_to_int = vocab
        self.int_to_str = {i:s for s,i in vocab.items()}

def encode(self, text):
    preprocessed = re.split(r'([,.?_!"()\']|--|\s)', text)
    preprocessed = [
        item.strip() for item in preprocessed if item.strip()
        ]
        ids = [self.str_to_int[s] for s in preprocessed]
        return ids

def decode(self, ids):
        text = " ".join([self.int_to_str[i] for i in ids])
        text = re.sub(r'\s+([,.?!"()\'])', r'\l', text)
        return text
```

We use the above encode function on random text

```
tokenizer = SimpleTokenizerV1(vocab)
text = """"It's the last he painted, you know,"
Mrs. Gisburn said with pardonable pride."""
ids = tokenizer.encode(text)
print(ids)
[1, 56, 2, 850, 988, 602, 533, 746, 5, 1126, 596, 5, 1, 67, 7, 38, 851, 1108, 754, 793, 7]
```

Next, we use the decode function to decode based on token ids generated in the previous step

```
print(tokenizer.decode(ids))
" It' s the last he painted, you know," Mrs. Gisburn said with pardonable pride.
```

The code below checks if the above process works with unknown words -- unfortunately, it doesn't

```
text = "Hello, do you like tea?"
print(tokenizer.encode(text))
KevError
                                          Traceback (most recent call
last)
Cell In[44], line 2
      1 text = "Hello, do you like tea?"
----> 2 print(tokenizer.encode(text))
Cell In[38], line 10, in SimpleTokenizerV1.encode(self, text)
      6 preprocessed = re.split(r'([,.? !"()\']|--|\s)', text)
      7 preprocessed = [
      8 item.strip() for item in preprocessed if item.strip()
      9 1
---> 10 ids = [self.str to int[s] for s in preprocessed]
     11 return ids
KeyError: 'Hello'
```

Below code handles unknown words with <|unk|> token and end of a segment with <|endoftext|> token

```
all_tokens = sorted(list(set(preprocessed)))
all_tokens.extend(["<|endoftext|>", "<|unk|>"])
vocab = {token:integer for integer,token in enumerate(all_tokens)}
print(len(vocab.items()))
```

Fetch last 5 entries with token and token ids

```
for i, item in enumerate(list(vocab.items())[-5:]):
    print(item)

('younger', 1127)
('your', 1128)
('yourself', 1129)
('<|endoftext|>', 1130)
('<|unk|>', 1131)
```

We incorporate the <|unk|> token and <|endoftext|> token into the encode and decode functions

```
class SimpleTokenizerV2:
    def __init__(self, vocab):
        self.str to int = vocab
        self.int to str = { i:s for s,i in vocab.items()}
    def encode(self, text):
        preprocessed = re.split(r'([,.:;?_!"()\']|--|\s)', text)
        preprocessed = [
        item.strip() for item in preprocessed if item.strip()
        preprocessed = [item if item in self.str to int
        else "<|unk|>" for item in preprocessed]
        ids = [self.str to int[s] for s in preprocessed]
        return ids
    def decode(self, ids):
        text = " ".join([self.int to str[i] for i in ids])
        text = re.sub(r'\s+([,.:;\overline{?}!"\overline{()}\'])', r'\1', text)
        return text
```

Application of encode and decode

```
tokenizer = SimpleTokenizerV2(vocab)
print(tokenizer.encode(text))

[1131, 5, 355, 1126, 628, 975, 10, 1130, 55, 988, 956, 984, 722, 988, 1131, 7]
print(tokenizer.decode(tokenizer.encode(text)))
<|unk|>, do you like tea? <|endoftext|> In the sunlit terraces of the <|unk|>.
```